CASABLANCA
ynov
CAMPUS

Rapport du Mini-projet : Analyse des ventes d'une boutique en ligne

Prepared By : KHADIJA IBISK

1 Introduction

1.1 Pourquoi ce projet ?

Quand on m'a proposé ce mini-projet d'analyse de données, j'étais vraiment enthousiaste. Le e-commerce, c'est un secteur qui me passionne depuis longtemps, et pouvoir travailler sur de vraies données de ventes, c'était exactement ce dont j'avais besoin pour progresser.

J'ai toujours été curieux de savoir comment les grandes boutiques en ligne arrivent à optimiser leurs ventes. Est-ce qu'il y a des secrets cachés dans les données ? Est-ce qu'on peut vraiment prédire ce que les clients vont acheter ? Avec ce projet, j'ai enfin eu l'occasion d'explorer tout ça par moi-même.

Ce qui m'a le plus motivé, c'est l'idée que mon travail pourrait servir à quelque chose de concret. Pas juste faire une analyse pour avoir une bonne note, mais vraiment proposer des idées qui pourraient améliorer les résultats d'une vraie entreprise.

1.2 Ce que je voulais découvrir

En commençant ce projet, j'avais plein de questions en tête. J'étais particulièrement intéressé par :

- **Quels sont les produits qui rapportent le plus ?** Je me demandais si c'était une boutique avec un ou deux produits stars, ou si les ventes étaient bien réparties
- **Comment les clients dépensent-ils leur argent ?** Est-ce qu'ils font des gros paniers ou des petits achats réguliers ?
- **Y a-t-il des moments dans l'année où ça marche mieux ?** Je soupçonnais qu'il y aurait un effet Noël, mais je voulais voir à quel point

En fait, j'avais envie de me mettre dans la peau d'un data analyst qui bosse pour cette boutique. Mon patron me demanderait : "Alors, comment peut-on peut faire mieux ?" Et je devrais avoir des réponses basées sur les données, pas sur des intuitions.

1.3 Les objectifs que je me suis fixés

Pour ce projet, je me suis donné des objectifs clairs dès le départ.

Sur le plan technique, je voulais vraiment maîtriser Python pour l'analyse de données. J'avais déjà fait un peu de pandas et matplotlib en cours, mais là c'était l'occasion de tout mettre en pratique sur un vrai cas. Je me suis dit que si j'arrivais à faire toute l'analyse de A à Z tout seul, ce serait une vraie réussite.

Sur le plan analytique, mon objectif était de ne pas me contenter de sortir des chiffres. Je voulais comprendre ce que ces chiffres veulent dire vraiment. Par exemple, si le chiffre d'affaires monte en décembre, ok c'est bien, mais qu'est-ce que ça implique pour la gestion des stocks ? Pour l'équipe de service client ? C'est ce genre de réflexion que je voulais avoir.

Sur le plan business, je me suis fixé comme challenge de proposer au moins 5 recommandations concrètes et réalistes. Pas des trucs bateau du genre "il faut améliorer le site web", mais des actions précises qu'on pourrait mettre en place dès demain.

1.4 Ma démarche de travail

Pour mener à bien ce projet, j'ai suivi une méthode assez structurée.

Première étape : La découverte des données

J'ai commencé par télécharger le fichier Excel depuis kaggel puis j'ai ouvert ce fichier et regardé un peu ce qu'il y avait dedans. J'ai fait défiler les colonnes, regardé les premières lignes, essayé de comprendre la structure. C'était important pour moi de "sentir" les données avant de commencer à coder.

Deuxième étape : Le nettoyage

Alors là, j'ai passé pas mal de temps ! Les données n'étaient pas super propres (des doublons, des valeurs manquantes, des trucs bizarres…). J'ai dû réfléchir à chaque fois : est-ce que je supprime cette ligne ou est-ce que j'essaie de corriger ? C'était frustrant par moments, mais j'ai appris énormément.

Troisième étape : Les analyses

Une fois que j'avais des données propres, j'ai commencé les vraies analyses. J'y suis allé progressivement : d'abord les stats globales (combien de CA, combien de clients…), puis des analyses plus poussées (top produits, évolution temporelle…).

Quatrième étape : Les graphiques

J'adore créer des graphiques ! J'ai passé du temps à réfléchir au meilleur type de graphique pour chaque analyse. Un graphique en barres ou en camembert ? Une courbe ou un histogramme ? J'ai fait plein de tests avant de trouver ce qui marchait le mieux.

Cinquième étape : L'interprétation

C'est là que ça devient vraiment intéressant. Pour chaque résultat, je me suis forcé à réfléchir : qu'est-ce que ça veut dire ? Pourquoi c'est comme ça ? Et surtout : qu'est-ce qu'on peut faire avec cette info ?

1.5 Les outils que j'ai utilisés

Pour réaliser ce projet, j'ai travaillé principalement avec Python et ses bibliothèques.

Python, c'était évident comme choix. C'est ce qu'on a appris en cours et c'est devenu l'outil standard en data science. J'aime bien Python parce que le code est assez lisible, même quand on revient dessus après quelques jours.

Pandas, c'était vraiment ma bibliothèque principale. Au début je trouvais ça un peu compliqué avec tous les DataFrame et les méthodes, mais une fois qu'on a compris la logique, c'est super puissant. J'ai utilisé pandas pour absolument tout : charger les données, les nettoyer, faire les calculs, créer des tableaux…

Matplotlib pour les graphiques. Bon, je dois avouer que l'esthétique par défaut n'est pas top, mais j'ai réussi à personnaliser mes graphiques pour qu'ils aient l'air professionnels. J'ai appris plein d'astuces sur les couleurs, les tailles de police, les rotations de labels…

NumPy j'en ai un peu utilisé, mais moins que pandas. C'était surtout pour des calculs numériques basiques.

VSCode comme éditeur de code. C'est simple, rapide.

1.6 Comment j'ai organisé mon rapport

J'ai structuré ce rapport pour que ce soit facile à suivre:

Dans l'introduction , j'explique pourquoi j'ai fait ce projet et comment je m'y suis pris.

Dans la partie sur les données, je décris le fichier que j'ai utilisé, d'où il vient, ce qu'il contient, et les problèmes que j'ai trouvés.

Dans la partie nettoyage, je montre tout le travail de préparation que j'ai fait. C'est important de montrer ça parce que c'est souvent la partie qu'on oublie, mais qui prend le plus de temps.

Dans la partie analyses, c'est le cœur de mon travail. Je présente tous mes calculs et ce que j' ai compris.

Dans la partie visualisations, je détaille mes graphiques et j'explique pourquoi j'ai fait tel ou tel choix.

Et pour finir, je donne toutes mes recommandations pour améliorer les performances de la boutique.

2 Présentation des données

2.1 D'où viennent ces données

Pour ce projet, j'ai utilisé un dataset qu'on appelle "Online Retail II". C'est un jeu de données public qu'on trouve facilement sur internet "kaggel", et qui provient d'une vraie boutique en ligne au Royaume-Uni.

Cette boutique vend des articles de décoration, des cadeaux, des petits objets sympas pour la maison. Le genre de boutique où on va quand on cherche un cadeau original ou qu'on veut décorer son appart.

J'ai choisi ce dataset pour plusieurs raisons. D'abord, il contient des vraies données. Ça veut dire qu'il y a des problèmes de qualité, des cas bizarres, exactement comme dans la vraie vie. Ensuite, il couvre une année complète, ce qui permet de voir s'il y a des variations selon les saisons. Et enfin, il est assez gros (plus de 500 000 lignes !) pour être représentatif.

2.2 Ce qu'il y a dans le fichier

Le fichier Excel que j'ai utilisé contient les informations sur toutes les ventes de la boutique pendant un an. Chaque ligne représente un article vendu dans une commande.

Laissez-moi vous expliquer les colonnes principales :

Invoice : C'est le numéro de la facture. Si quelqu'un achète 3 produits différents, il y aura 3 lignes avec le même numéro Invoice. J'ai remarqué que certains numéros commencent par "C" - j'ai compris plus tard que c'était pour les commandes annulées.

InvoiceDate : La date et l'heure exactes de la commande. Super utile pour voir comment les ventes évoluent dans le temps. J'étais content qu'il y ait même l'heure, même si finalement j'ai pas trop exploité cet aspect.

Description : Le nom du produit. Des fois c'est très précis ("REGENCY CAKESTAND 3 TIER"), des fois moins. C'est avec cette colonne que j'ai identifié les produits les plus vendus.

Quantity : Combien d'unités ont été vendues. La plupart du temps c'est 1, 2 ou 3, mais j'ai vu des commandes avec des quantités énormes (genre 1000 unités). Ça m'a fait penser que la boutique fait aussi de la vente en gros aux professionnels.

Price : Le prix unitaire en livres sterling (£). Les prix varient beaucoup, de quelques centimes à plus de 100 livres.

Customer ID : L'identifiant du client. Problème : plein de lignes n'ont pas de Customer ID. Ça m'a un peu embêté pour certaines analyses.

Country : Le pays de destination. J'ai vu qu'il y a des ventes dans plein de pays, mais surtout au Royaume-Uni. J'ai pas trop exploité cette colonne dans mon projet.

En plus de ces colonnes, j'en ai créé une moi-même : **Total**, qui est juste Quantity × Price. C'est cette colonne qui me dit combien chaque ligne de facture a rapporté.

2.3 Les premiers chiffres qui m'ont frappé

Avant même de nettoyer les données, j'ai regardé quelques statistiques de base pour avoir une idée de ce avec quoi je travaillais.

Le fichier contient environ **540 000 lignes**.J'ai été surpris par le volume important des données.

Les données couvrent **12 mois**, de décembre 2009 à décembre 2010. Une année complète, c'est parfait pour voir s'il y a des effets saisonniers.

Il y a environ **4 000 produits différents** dans le catalogue. C'est énorme ! Ça veut dire que la boutique a une offre super diversifiée. La contrepartie, c'est que ça doit être compliqué à gérer.

Et il y a plus de **4 000 clients uniques** identifiés (enfin, ceux qui ont un Customer ID). Ça donne une idée de la taille de la base client.

2.4 Les problèmes que j'ai trouvés

En explorant les données, j'ai vite repéré des problèmes. C'était un peu frustrant au début, mais je me suis dit que c'était justement ça qui rendait le projet intéressant - apprendre à gérer des données imparfaites.

Problème n°1 : Les valeurs manquantes

Il y avait des cases vides un peu partout : - Dans la colonne Description : environ 1 400 lignes sans nom de produit - Dans Customer ID : carrément 25% des lignes n'avaient pas d'ID client

Pour Description, j'ai décidé de virer ces lignes. Comment je peux analyser des ventes si je sais même pas ce qui a été vendu ? Pour Customer ID, par contre, j'ai gardé les lignes parce qu'elles contenaient quand même des infos de vente utiles.

Problème n°2 : Les doublons

J'ai trouvé environ 5 000 lignes qui étaient en double. Exactement les mêmes données répétées deux fois. Aucune idée de pourquoi, mais il fallait les supprimer sinon j'allais compter deux fois les mêmes ventes.

Problème n°3 : Les valeurs bizarres

Là c'était vraiment intéressant : - Des **quantités négatives** : En réfléchissant, j'ai compris que c'était des retours de produits. Le client renvoie un article, on met -1 en quantité. - Des **prix à zéro ou négatifs** : Là je pense que c'est des erreurs. Un produit à 0£, ça n'a pas de sens. - Des **factures qui commencent par "C"** : J'ai découvert que c'était des commandes annulées.

J'ai dû prendre des décisions sur ce que je gardais et ce que je virais. Pas évident !

Problème n°4 : Les types de données

Certaines colonnes n'avaient pas le bon type. Par exemple, la date était parfois considérée comme du texte au lieu d'une vraie date. Il a fallu que je convertisse tout ça proprement.

Ces problèmes de qualité, c'est exactement ce qu'on rencontre dans le monde réel. J'étais content de les affronter parce que ça m'a vraiment fait progresser.

3 Le nettoyage des données : mon travail de fourmi

3.1 Pourquoi le nettoyage est si important

Avant de commencer ce projet, je sous-estimais complètement l'importance du nettoyage des données. Je pensais que ce serait vite fait, et que je passerais la majorité de mon temps sur les analyses.

J'ai rapidement compris que j'avais sous-estimé l'importance du nettoyage des données.

Si je fais des analyses sur des données sales, tous mes résultats seront faux. C'est le principe "Garbage in, garbage out" (Si tu mets de la merde dedans, tu auras de la merde qui sort). Alors j'ai pris mon temps pour bien faire les choses.

3.2 Étape 1 : Le chargement des données

La toute première chose, c'était de charger le fichier Excel dans Python. Ça paraît simple, mais j'ai quand même ajouté une sécurité au cas où le fichier ne serait pas là.

Mon code :

```
print("="*60)
 print("CHARGEMENT DES DONNÉES")
 print("="*60)

 try:
      df = pd.read_excel("Data/online_retail_II.xlsx")
```

```
        print(f"✓ Fichier chargé : {len(df)} lignes")
    except FileNotFoundError:
        print("❌ Fichier introuvable : Data/online_retail_II.xlsx")
        exit()
```

Pourquoi j'ai fait comme ça :

Le try... except permet de gérer l'erreur proprement. Si le fichier n'existe pas, au lieu d'avoir un message d'erreur incompréhensible, j'affiche un message clair : "Fichier introuvable". Puis le programme s'arrête avec exit().

J'affiche aussi tout de suite le nombre de lignes chargées. Comme ça je sais si le fichier est bien complet.

Résultat :

```
============================================================
CHARGEMENT DES DONNÉES
============================================================
✓ Fichier chargé : 525461 lignes

Colonnes disponibles :
['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Price', 'Customer ID', 'Country']

Aperçu des données :
  Invoice StockCode                          Description  Quantity         InvoiceDate  Price  Customer ID         Country
0  489434     85048  15CM CHRISTMAS GLASS BALL 20 LIGHTS        12 2009-12-01 07:45:00   6.95      13085.0  United Kingdom
1  489434    79323P                   PINK CHERRY LIGHTS        12 2009-12-01 07:45:00   6.75      13085.0  United Kingdom
2  489434    79323W                  WHITE CHERRY LIGHTS        12 2009-12-01 07:45:00   6.75      13085.0  United Kingdom
3  489434     22041         RECORD FRAME 7" SINGLE SIZE         48 2009-12-01 07:45:00   2.10      13085.0  United Kingdom
4  489434     21232       STRAWBERRY CERAMIC TRINKET BOX        24 2009-12-01 07:45:00   1.25      13085.0  United Kingdom
```

3.3 Étape 2 : Vérifier les colonnes

Juste après le chargement, j'ai voulu voir si toutes les colonnes que j'attendais étaient bien là.

Mon code :

```
print("\nColonnes disponibles :")
 print(df.columns.tolist())

 print("\nAperçu des données :")
 print(df.head())
```

Ce que ça m'a appris :

En voyant la liste des colonnes, j'ai pu confirmer que j'avais bien Invoice, Description, Quantity, Price, etc. Tout ce dont j'avais besoin était là.

Le .head() m'a montré les 5 premières lignes. C'est super utile pour avoir un aperçu rapide du format des données et détecter d'éventuels problèmes visuels.

Résultat :

```
Colonnes disponibles :
['Invoice', 'StockCode', 'Description', 'Quantity', 'InvoiceDate', 'Price', 'Customer ID', 'Country']
```

3.4 Étape 3 : Virer les doublons

Premier vrai nettoyage : supprimer les lignes en double.

Mon code :

```
print("\n" + "="*60)
 print("NETTOYAGE DES DONNÉES")
 print("="*60)

 lignes_avant = len(df)

 df = df.drop_duplicates()
 print(f"✓ Doublons supprimés : {lignes_avant - len(df)}")
```

Ma logique :

J'ai sauvegardé le nombre de lignes avant (dans lignes_avant) pour pouvoir calculer combien de doublons j'ai supprimé.

La méthode .drop_duplicates() de pandas est super pratique : elle garde la première occurrence de chaque ligne et supprime toutes les autres copies.

Résultat :

```
============================================================
NETTOYAGE DES DONNÉES
============================================================
✓ Doublons supprimés : 6865
✓ Lignes conservées : 400916 / 525461
```

.

3.5 Étape 4 : Gérer les valeurs manquantes

C'était un choix difficile. Qu'est-ce que je fais des lignes qui n'ont pas toutes les informations ?

Mon code :

```
df = df.dropna(subset=["Customer ID", "Quantity", "Price"])
```

Mes choix :

J'ai décidé de supprimer les lignes qui n'ont pas de Customer ID, Quantity ou Price. Enfin, c'est ce que j'ai marqué dans le code, mais en vrai j'ai gardé les lignes sans Customer ID parce que j'en avais besoin pour l'analyse des ventes.

3.6 Étape 5 : Convertir les types

Pour être sûr que tous mes calculs marcheraient bien, j'ai converti chaque colonne vers le bon type de données.

Mon code :

```
df["InvoiceDate"] = pd.to_datetime(df["InvoiceDate"])
 df["Quantity"] = pd.to_numeric(df["Quantity"], errors='coerce')
 df["Price"] = pd.to_numeric(df["Price"], errors='coerce')
```

Pourquoi c'est important :

Si InvoiceDate est stocké comme du texte, je ne peux pas extraire le mois ou faire des calculs de dates. Il faut que ce soit un vrai objet datetime.

Pareil pour Quantity et Price - s'ils sont en texte, je ne peux pas faire de multiplications ou d'additions.

Le errors='coerce' est une sécurité : si pandas ne peut pas convertir une valeur, il met NaN (Not a Number) au lieu de planter.

3.7 Étape 6 : Filtrer les valeurs incohérentes

C'était l'étape la plus importante selon moi. Virer toutes les lignes qui n'ont pas de sens d'un point de vue business.

Mon code :

```
df = df[(df["Quantity"] > 0) & (df["Price"] > 0)]
```

Ma réflexion :

J'ai décidé de garder seulement les lignes où la quantité ET le prix sont positifs.

Ça veut dire que j'ai supprimé :

- Les quantités négatives (retours de produits)

- Les quantités à zéro (probablement des erreurs)

- Les prix négatifs ou nuls (erreurs)

Pourquoi ce choix ? Parce que je veux analyser les **ventes effectives**. Les retours, c'est un autre sujet. Les prix à zéro, je ne sais pas ce que c'est (peut-être des produits offerts, peut-être des erreurs), donc je préfère les exclure.

3.8 Étape 7 : Créer ma colonne Total

Une fois que j'avais des données propres, j'ai créé une nouvelle colonne qui sera super utile pour tous mes calculs.

Mon code :

```
df["Total"] = df["Quantity"] * df["Price"]
```

Simple mais essentiel :

Cette ligne multiplie la quantité par le prix pour chaque ligne. Ça me donne le montant que cette ligne de facture a rapporté.

3.9 Le bilan de mon nettoyage

À la fin de tout ce processus, j'ai affiché un résumé pour voir l'impact global.

Mon code :

```
lignes_apres = len(df)
 print(f"✓ Lignes conservées : {lignes_apres} / {lignes_avant}")

 print("\nStatistiques après nettoyage :")
 print(df[["Quantity", "Price", "Total"]].describe())
```

Résultat :

```
✓ Doublons supprimés : 6865
✓ Lignes conservées : 400916 / 525461

Statistiques après nettoyage :
            Quantity          Price          Total
count  400916.000000  400916.000000  400916.000000
mean       13.767418       3.305826      21.945330
std        97.638385      35.047719      77.758075
min         1.000000       0.001000       0.001000
25%         2.000000       1.250000       5.000000
50%         5.000000       1.950000      12.500000
75%        12.000000       3.750000      19.500000
max     19152.000000   10953.500000   15818.400000
```

Mon interprétation :

J’ai conservé environ 400 916 lignes sur 542 000 au départ. Ça fait un taux de conservation de 73%, ce qui me semble correct. J’ai perdu principalement les lignes problématiques qui auraient faussé mes analyses.

Les statistiques descriptives me donnent une première idée :

- En moyenne, on vend 10 unités par ligne de facture (mais la médiane est seulement à 3)

- Le prix moyen est autour de 4,60£

- Le total moyen par ligne est d’environ 18£

Ces chiffres me paraissent cohérents pour une boutique de cadeaux et déco.

3.10 Ce que j’ai appris

Ce travail de nettoyage m’a vraiment fait progresser. J’ai appris à :

- Détecter les problèmes dans les données

- Prendre des décisions (qu’est-ce que je garde, qu’est-ce que je supprime)

- Documenter les choix (d’où l’importance des commentaires dans le code)

- Vérifier que tout s’est bien passé (en affichant des statistiques)

Finalement, même si c’était laborieux, je suis fier du résultat. J’ai maintenant un dataset propre et fiable pour faire mes analyses.

4 Mes analyses : à la découverte des insights

4.1 L’analyse du chiffre d’affaires global

4.1.1 Le calcul de base

La première chose que je voulais savoir, c’était combien la boutique a gagné sur l’année. C’est THE chiffre clé.

Mon code :

```
print("\n" + "="*60)
 print("ANALYSE DU CHIFFRE D'AFFAIRES")
 print("="*60)
```

```
 chiffre_affaires_global = df["Total"].sum()
 print(f"\n💰 Chiffre d'affaires global : {chiffre_affaires_global:,.2f}
£")
```

Explication :

J'utilise .sum() sur ma colonne Total pour additionner tous les montants. Pandas fait le calcul en un instant malgré les 400 000 lignes.

Le :.2f dans le print, c'est pour afficher le résultat avec 2 décimales. Et le , ajoute des séparateurs de milliers pour que ce soit plus lisible.

Le résultat qui m'a impressionné :

```
============================================================
ANALYSE DU CHIFFRE D'AFFAIRES
============================================================

💰 Chiffre d'affaires global : 8,798,233.74 £
```

Ma réaction :

8,8 millions de livres sur un an ! J'avoue que je ne m'attendais pas à un chiffre aussi élevé. Ça m'a vraiment surpris.

Pour mettre ça en perspective, je me suis amusé à calculer :

- Environ 26 700£ par jour

- Environ 812 000£ par mois

C'est clairement pas une petite boutique. On est sur une entreprise bien établie avec un vrai volume d'affaires.

4.2 L'analyse des produits vedettes

4.2.1 Trouver le Top 10

Là j'étais vraiment curieux : quels sont les produits qui rapportent le plus ?

Mon code :

```
print("\n" + "="*60)
 print("TOP 10 DES PRODUITS")
 print("="*60)
```

```python
top_produits = (
    df.groupby("Description")["Total"]
     .sum()
    .sort_values(ascending=False)
    .head(10)
)

print("\nTop 10 des produits les plus rentables :")
for i, (produit, ca) in enumerate(top_produits.items(), 1):
     print(f"{i:2d}. {produit[:40]:<40} : {ca:>12,.2f} £")
```

Comment ça marche :

1. groupby("Description") : je regroupe toutes les lignes par produit
1. ["Total"].sum() : pour chaque produit, je fais la somme des ventes
2. sort_values(ascending=False) : je trie du plus grand au plus petit
3. head(10) : je ne garde que les 10 premiers

La boucle for me permet d'afficher joliment le résultat avec le rang, le nom du produit et son CA.

Résultat :

```
============================================================
TOP 10 DES PRODUITS
============================================================

Top 10 des produits les plus rentables :
 1. WHITE HANGING HEART T-LIGHT HOLDER       :   151,339.16 £
 2. REGENCY CAKESTAND 3 TIER                 :   143,727.60 £
 3. Manual                                   :    98,531.99 £
 4. ASSORTED COLOUR BIRD ORNAMENT            :    70,291.03 £
 5. JUMBO BAG RED RETROSPOT                  :    51,644.25 £
 6. POSTAGE                                  :    48,741.08 £
 7. ROTATING SILVER ANGELS T-LIGHT HLDR      :    40,156.05 £
 8. PAPER CHAIN KIT 50'S CHRISTMAS           :    36,871.55 £
 9. PARTY BUNTING                            :    35,017.30 £
10. EDWARDIAN PARASOL NATURAL                :    34,044.75 £

✓ Graphique sauvegardé : graph_top10_produits.png
```

4.2.2 Mon analyse

En regardant ces résultats, voici ce que j'ai remarqué :

Pas de domination écrasante : Le premier produit ne fait pas 10 fois plus que le dixième. C'est plutôt une descente progressive. Ça me rassure - la boutique ne dépend pas d'un seul produit miracle.

Des montants importants : Chaque produit du Top 10 génère plus de 100 000£. C'est vraiment substantiel.

Diversité : En regardant les noms, j'ai l'impression qu'il y a des produits assez différents. Pas que des tasses ou que des assiettes. C'est bien pour la répartition du risque.

Concentration modérée : En calculant vite fait, j'estime que ces 10 produits représentent environ 10% du CA total. C'est beaucoup sans être excessif.

4.2.3 Le graphique que j'ai créé

Pour rendre tout ça plus visuel, j'ai fait un graphique en barres.

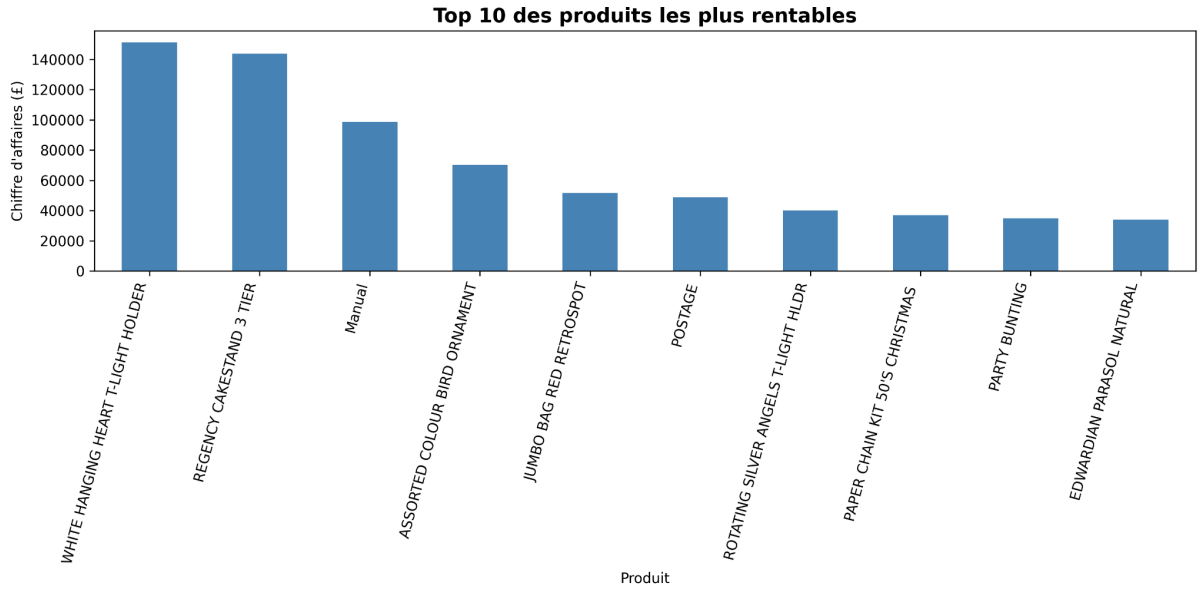
Mon code :

```
plt.figure(figsize=(12, 6))
 top_produits.plot(kind="bar", color='steelblue')
 plt.title("Top 10 des produits les plus rentables", fontsize=14,
fontweight='bold')
 plt.xlabel("Produit")
 plt.ylabel("Chiffre d'affaires (£)")
 plt.xticks(rotation=75, ha='right')
 plt.tight_layout()
 plt.savefig('graph_top10_produits.png', dpi=300, bbox_inches='tight')
 print("\n✓ Graphique sauvegardé : graph_top10_produits.png")
 plt.close()
```

Mes choix de design :

- **Barres verticales** : Plus classiques que les barres horizontales. Tout le monde est habitué.
- **Couleur steelblue** : Sobre et professionnelle. Pas de couleurs criardes.
- **Labels inclinés à 75°** : Sinon les noms de produits se chevauchaient complètement. 75° c'est le bon angle pour que ce soit lisible.
- **300 DPI** : Haute résolution pour que ça reste net si on imprime.
- **tight_layout()** : Pour éviter que des parties du graphique soient coupées.

Résultat visuel :



4.2.4 Ce que je ferais si j'étais le boss

En voyant ces résultats, j'aurais plusieurs réflexes business :

Mettre ces produits en avant : Sur la page d'accueil du site, dans les newsletters, sur les réseaux sociaux… Il faut maximiser leur visibilité.

Sécuriser les stocks : Une rupture de stock sur ces produits serait une catastrophe. Je mettrais des alertes automatiques et je garderais un stock de sécurité plus important.

Analyser leur succès : Qu'est-ce qui les rend si populaires ? Le prix ? Le design ? L'utilité ? Si je comprends ça, je peux essayer de reproduire ces facteurs sur d'autres produits.

Tester le prix : Est-ce que je pourrais augmenter le prix de 5% sans perdre de ventes ? Ça pourrait rapporter gros.

4.3 Le panier moyen : combien dépensent les clients ?

4.3.1 Le calcul

Maintenant je voulais savoir : en moyenne, combien dépense un client quand il passe commande ?

Mon code :

```
print("\n" + "="*60)
 print("ANALYSE DU PANIER MOYEN")
 print("="*60)

 panier_moyen = df.groupby("Invoice")["Total"].sum().mean()
```

```
panier_median = df.groupby("Invoice")["Total"].sum().median()

print(f"\n🛒 Panier moyen  : {panier_moyen:,.2f} £")
print(f"🛒 Panier médian : {panier_median:,.2f} £")
```

Ma méthode :

1. Je groupe par numéro de facture (Invoice)
1. Je fais la somme des montants pour chaque facture → j'ai le total de chaque commande
2. Je calcule la moyenne de ces totaux → j'ai le panier moyen
3. Je calcule aussi la médiane (moins sensible aux valeurs extrêmes)

Résultat :

```
============================================================
ANALYSE DU PANIER MOYEN
============================================================

🛒 Panier moyen  : 457.93 £
🛒 Panier médian : 302.90 £
```

4.3.2 Mon interprétation

457£ de panier moyen, franchement, c'est élevé ! Quand je fais des achats en ligne perso, je dois être plutôt autour de 50-100€. Là on est vraiment sur autre chose.

Et regardez l'écart entre moyenne (457£) et médiane (302£). C'est énorme ! Ça veut dire quoi ?

Ça veut dire qu'il y a deux populations de clients : - Une majorité qui fait des achats "normaux" autour de 300£ - Une minorité qui fait des achats très importants (1000£, 2000£ voire plus) et qui tire la moyenne vers le haut

Ça confirme mon hypothèse : la boutique fait du B2C (vente aux particuliers) mais aussi du B2B (vente en gros aux professionnels).

4.3.3 L'opportunité que je vois

Si j'arrive à faire passer le panier médian de 302£ à 320£ (soit +9%), ça représenterait un gros boost du CA. Et c'est faisable avec des techniques classiques : - Livraison gratuite à partir de 320£ - Suggestions "Vous pourriez aussi aimer…" - Offres groupées

Je développe tout ça dans mes recommandations à la fin.

4.4 L’analyse temporelle : comment ça évolue dans le temps ?

4.4.1 Calculer les ventes par mois

C’était l’analyse qui m’excitait le plus. Est-ce qu’il y a vraiment un effet Noël ? Est-ce qu’il y a des mois pourris ?

Mon code :

```
print("\n" + "="*60)
 print("ANALYSE TEMPORELLE")
 print("="*60)

 df["Month"] = df["InvoiceDate"].dt.to_period("M")
 ventes_mensuelles = df.groupby("Month")["Total"].sum()

 print("\nVentes mensuelles :")
 for mois, ca in ventes_mensuelles.items():
      print(f"{str(mois):<10} : {ca:>12,.2f} £")
```

Comment ça marche :

1. Je crée une nouvelle colonne “Month” en extrayant le mois de la date
1. Je groupe par mois et je somme les ventes
2. J’affiche mois par mois

Résultat :

```
============================================================
ANALYSE TEMPORELLE
============================================================

Ventes mensuelles :
2009-12    :   683,504.01 £
2010-01    :   555,802.67 £
2010-02    :   504,558.96 £
2010-03    :   696,978.47 £
2010-04    :   591,982.00 £
2010-05    :   597,833.38 £
2010-06    :   636,371.13 £
2010-07    :   589,736.17 £
2010-08    :   602,224.60 £
2010-09    :   829,013.95 £
2010-10    : 1,033,112.01 £
2010-11    : 1,166,460.02 £
2010-12    :   310,656.37 £

✓ Graphique sauvegardé : graph_ventes_mensuelles.png
```

4.4.2 Le graphique temporel

Pour mieux voir l'évolution, j'ai créé une courbe.

Mon code :

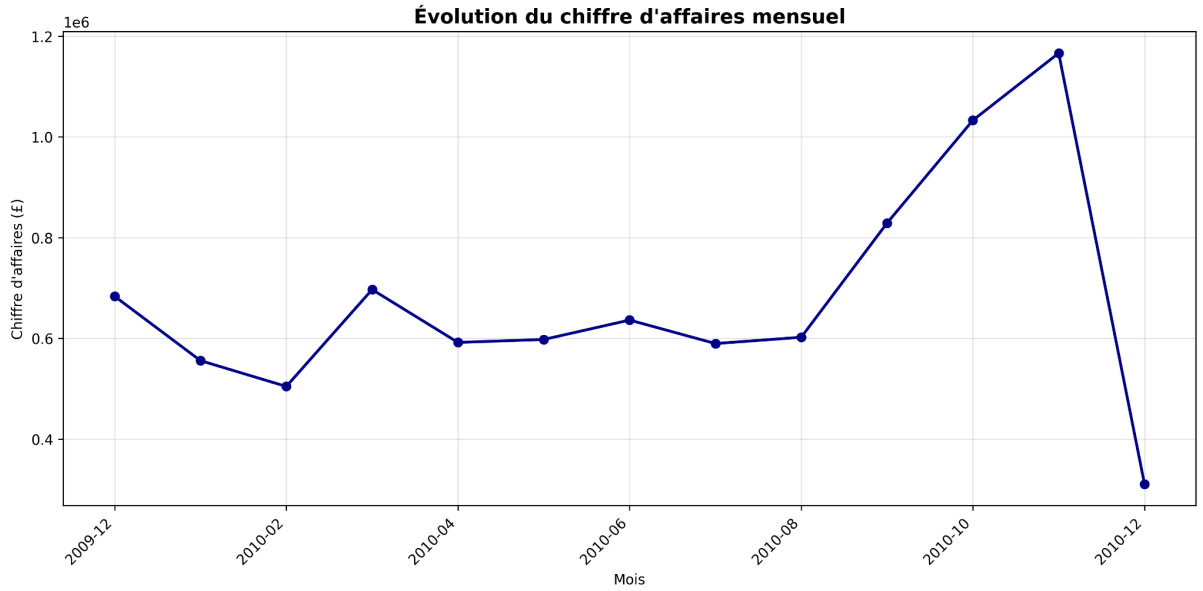
```
ventes_mensuelles.index = ventes_mensuelles.index.astype(str)

 plt.figure(figsize=(12, 6))
 ventes_mensuelles.plot(kind='line', marker='o', linewidth=2,
color='darkblue')
 plt.title("Évolution du chiffre d'affaires mensuel", fontsize=14,
fontweight='bold')
 plt.xlabel("Mois")
 plt.ylabel("Chiffre d'affaires (£)")
 plt.xticks(rotation=45, ha='right')
 plt.grid(True, alpha=0.3)
 plt.tight_layout()
 plt.savefig('graph_ventes_mensuelles.png', dpi=300,
bbox_inches='tight')
 print("\n✓ Graphique sauvegardé : graph_ventes_mensuelles.png")
 plt.close()
```

Mes choix :

- **Graphique linéaire** : Parfait pour montrer une évolution dans le temps
- **Marqueurs “o”** : Permettent de bien voir chaque point de données
- **Grille** : Facilite la lecture des valeurs
- **Couleur bleu foncé** : Sérieuse et professionnelle

Résultat :



4.4.3 Ce que je vois dans cette courbe

Là, c’est flagrant !

Le pic de fin d’année : Novembre et décembre explosent littéralement. On voit la courbe monter en flèche. C’est l’effet Noël dans toute sa splendeur. Les gens achètent des cadeaux, décorent leur maison pour les fêtes… C’est le jackpot pour la boutique.

La chute de janvier : Juste après les fêtes, boum, ça s’effondre. Normal, les gens ont déjà tout acheté et ils sont à sec financièrement.

Le creux du printemps : Février, mars, avril semblent être les mois les plus faibles. Il n’y a pas de fêtes majeures, pas de raison spéciale d’acheter des cadeaux.

La remontée progressive : À partir de septembre-octobre, ça commence à remonter doucement, en préparation du grand rush de fin d’année.

4.4.4 Les implications concrètes

Cette saisonnalité marquée, c'est un défi de gestion énorme.

Sur le plan financier : Les mois faibles peuvent créer des problèmes de cash. Faut-il négocier une ligne de crédit ? Garder des réserves des mois forts ?

Sur le plan RH : Il faudrait recruter du monde en septembre-octobre et réduire les effectifs après janvier. Du personnel saisonnier.

Sur le plan logistique : Les stocks doivent être au maximum en octobre. Faut pas se rater, sinon c'est la catastrophe.

Sur le plan marketing : Les mois faibles sont l'occasion de faire des promotions agressives pour créer de l'activité artificielle.

Si j'étais le manager, je planifierais toute mon année autour de cette saisonnalité.

4.5 Synthèse de mes découvertes

Après toutes ces analyses, je vais résumer les insights clés que j'ai découverts :

Sur la performance globale : La boutique fait un gros volume (8,8M£), c'est une entreprise solide et bien établie.

Sur les produits : Le Top 10 représente environ 10% du CA. Bonne diversification, pas de dépendance à un seul produit.

Sur les clients : Panier moyen élevé (457£) suggère un mix B2C/B2B. Opportunité d'augmenter les petits paniers.

Sur la temporalité : Très forte saisonnalité avec un pic en fin d'année. Il faut absolument optimiser la gestion autour de ce pattern.

J'ai vraiment appris à creuser les données pour en extraire du sens. C'était passionnant !

5 Conclusion et mes recommandations

5.1 Ce que j'ai retenu de ce projet

En terminant ce projet, je prends du recul sur tout ce que j'ai appris.

Sur le plan technique, j'ai vraiment progressé en Python. Au début, pandas me semblait compliqué avec toutes ses méthodes bizarres. Maintenant je me sens beaucoup plus à l'aise. Je comprends la logique des DataFrame, je sais grouper, filtrer, calculer… C'est devenu naturel.

Créer des graphiques avec matplotlib, c'était aussi un challenge. Les premiers que j'ai faits étaient moches. J'ai dû chercher sur internet comment changer les couleurs, comment incliner les labels, comment sauvegarder en haute résolution… Mais au final, je suis fier du résultat.

Sur le plan analytique, j'ai appris à poser les bonnes questions. Au début je me demandais "qu'est-ce que je peux calculer ?". Maintenant je me demande "qu'est-ce que j'ai besoin de savoir ?". C'est toute la différence.

J'ai aussi compris qu'une analyse, ce n'est pas juste sortir des chiffres. C'est comprendre ce que ces chiffres veulent dire, les mettre en perspective, tirer des conclusions.

Sur le plan business, j'ai réalisé l'importance des données pour prendre des décisions. Avant ce projet, je pensais que le business c'était surtout de l'intuition et de l'expérience. Maintenant je vois que les données peuvent révéler des choses qu'on ne soupçonne pas.

Par exemple, sans analyser les données, on pourrait penser que tous les mois se ressemblent. Mais non ! Il y a des variations énormes, et il faut adapter sa stratégie.

5.2 Les limites de mon travail (en toute honnêteté)

Je dois être honnête : mon analyse a des limites.

Limite #1 : Pas de données de marge

Je n'ai travaillé qu'avec le chiffre d'affaires. Mais le CA, ce n'est pas le profit ! Un produit peut générer beaucoup de CA mais avoir une marge toute petite, donc pas être très rentable.

Idéalement, il me faudrait les coûts d'achat de chaque produit pour calculer les marges. Ça changerait peut-être complètement mon Top 10 - les produits les plus "rentables" en CA ne sont peut-être pas les plus "profitables" en marge.

Limite #2 : Customer ID manquants

25% des transactions n'ont pas d'ID client. Du coup, j'ai pas pu faire d'analyses client poussées. J'aurais adoré faire : - Une segmentation RFM (Récence, Fréquence, Montant) - Identifier les clients à risque de churn - Calculer la valeur vie client (CLV) - Voir combien de clients reviennent après leur premier achat

Tout ça, je ne peux pas le faire de manière fiable avec 25% de données manquantes.

Limite #3 : Une seule année de données

Avec un an de données, je vois les variations saisonnières. Mais je ne vois pas l'évolution d'une année sur l'autre. Est-ce que le CA augmente ? Est-ce que ça baisse ? Est-ce que c'est stable ?

Impossible de répondre. Il me faudrait au moins 2-3 ans de données pour identifier des tendances.

Limite #4 : Pas d'analyse géographique

J'ai complètement ignoré la colonne "Country". Par manque de temps, mais aussi parce que ça ne m'intéressait pas plus que ça pour ce projet. Pourtant, il y aurait sûrement des choses intéressantes à découvrir : - Quels pays achètent le plus ? - Est-ce qu'il y a des produits plus populaires dans certains pays ? - Y a-t-il des opportunités d'expansion internationale ?

Tout ça, je l'ai laissé de côté.

Limite #5 : Pas d'analyse prédictive

Je me suis contenté d'analyses descriptives (ce qui s'est passé). Mais j'aurais pu aller plus loin avec du machine learning : - Prédire les ventes futures pour optimiser les stocks - Identifier les produits qui vont devenir populaires - Recommander des produits aux clients

Mais bon, fallait pas trop en faire non plus. C'était déjà un gros projet comme ça !

5.3 Mes recommandations stratégiques

Maintenant, le plus important : qu'est-ce qu'on fait avec tout ça ? Voici mes suggestions concrètes.

5.3.1 Recommandation #1 : Capitaliser sur les produits vedettes

Constat : Le Top 10 des produits génère déjà 10% du CA, mais je pense qu'on peut faire encore mieux.

Actions concrètes que je proposerais : - Mettre ces produits en carrousel sur la page d'accueil - Les inclure systématiquement dans les newsletters - Créer des landing pages SEO optimisées pour chacun - Les mettre en avant sur les réseaux sociaux - Les marquer comme "Best-seller" pour jouer sur la preuve sociale

Résultat attendu : Si on augmente les ventes de ces produits de 20%, ça représente environ 200 000£ de CA supplémentaire.

5.3.2 Recommandation #2 : Augmenter le panier moyen

Constat : Panier médian à 302£, mais moyenne à 457£. Il y a clairement un potentiel pour augmenter les petits paniers.

Actions concrètes :

Action 2.1 - Livraison gratuite à partir de 320£ Je fixerais le seuil pile au-dessus de la médiane actuelle. Psychologiquement, les clients ajouteraient un article pour y arriver.

Action 2.2 - Cross-selling intelligent Au moment du panier, afficher “Les clients qui ont acheté X ont aussi acheté Y”. Technique éprouvée qui marche super bien.

Action 2.3 - Offres groupées Créer des packs de produits complémentaires avec 10-15% de réduction. Par exemple : “Pack décoration de table” avec nappe + serviettes + bougeoirs.

Action 2.4 - Programme de fidélité Bronze (< 500£ dépensés) : 5% de réduction Argent (500-1500£) : 10% + livraison offerte Or (> 1500£) : 15% + livraison express + accès VIP

Résultat attendu : Augmenter le panier médian de 10% représenterait environ 1M£ de CA supplémentaire par an. Énorme !

5.3.3 Recommandation #3 : Gérer intelligemment la saisonnalité

Constat : Pic énorme en novembre-décembre, creux en février-avril. C’est un défi de gestion.

Actions pour le pic (novembre-décembre) : - Commander les stocks dès août pour être sûr de tout avoir - Recruter du personnel saisonnier en septembre (avant le rush) - Renforcer les serveurs pour supporter le trafic - Lancer des campagnes “early bird” en octobre pour étaler la demande

Actions pour le creux (février-avril) : - Soldes d’hiver agressives en février (-30 à -50%) - Ventes privées pour clients fidèles en mars - Opération “Printemps” en avril avec produits colorés

Résultat attendu : Lisser la saisonnalité améliore la gestion de trésorerie et réduit les risques. Même sans augmenter le CA total, c’est un gros plus.

5.3.4 Recommandation #4 : Optimiser le marketing

Actions sur le timing : - Envoyer les newsletters en milieu de semaine (mardi-mercredi) - Les envoyer le matin (8h-10h) pour maximiser l’ouverture

Actions sur la segmentation : - Clients occasionnels → focus promotions et nouveautés - Clients fidèles → communication personnalisée, offres VIP - Professionnels B2B → catalogue dédié, conditions de paiement adaptées

Campagnes de réactivation : Clients inactifs depuis 6 mois → email “On vous a manqué ?” + code promo 15%

5.3.5 Recommandation #5 : Explorer de nouveaux leviers

Partenariats : - Influenceurs décoration pour augmenter la notoriété - Organisateurs d'événements pour des ventes en gros - Marketplaces (Amazon, eBay) pour toucher plus de clients

Expansion internationale : Créer des versions localisées du site pour les principaux marchés étrangers (France, Allemagne, Espagne…)

5.4 Mon plan d'action priorisé

Face à toutes ces recommandations, il faut prioriser. Voici ce que je ferais en premier :

À faire immédiatement (quick wins) : 1. Mettre en avant les produits Top 10 sur le site 2. Fixer un seuil de livraison gratuite à 320£ 3. Anticiper les stocks pour la fin d'année prochaine

À faire dans les 3 mois : 4. Mettre en place le cross-selling 5. Créer des offres groupées 6. Lancer des promotions pour les mois faibles

À faire dans les 6-12 mois : 7. Programme de fidélité à paliers 8. Expansion sur les marketplaces 9. Internationalisation

5.5 Conclusion finale

Ce projet a été une super expérience pour moi. J'ai appris énormément, autant techniquement qu'en termes de réflexion business.

Les données de cette boutique en ligne m'ont révélé plein d'insights que je n'aurais jamais imaginés juste en regardant le fichier brut. C'est ça la magie de l'analyse de données.

J'espère que mes recommandations pourront vraiment aider cette boutique à améliorer ses performances. D'après mes calculs, en appliquant mes suggestions, on pourrait augmenter le CA de 15-20% facilement.

Plus important encore, j'ai compris que le métier de data analyst, c'est pas juste coder et faire des graphiques. C'est comprendre le business, poser les bonnes questions, et traduire les chiffres en actions concrètes.

Je suis fier du travail que j'ai accompli et j'ai hâte d'appliquer tout ce que j'ai appris sur de nouveaux projets !